

Machine Learning

Enseignante: Bènéne Fradi Boumiza

Niveau : GL4


Année universitaire: 2025/2026

La Régression

❑ Principe de la Régression

La **régression** est une méthode qui permet de prédire une **valeur continue** à partir de variables explicatives.

- Contrairement à la classification (qui attribue une étiquette ou une classe), la régression cherche une **quantité numérique**.
- Exemple intuitif : prédire la **taille d'une personne** en fonction de son âge.



Caractéristiques principales :

- La sortie (Y) est une variable quantitative continue.
- On cherche à trouver une relation entre les variables d'entrée (X) et la sortie (Y).
- On mesure la qualité du modèle à l'aide d'une **fonction coût** (par ex. l'erreur quadratique moyenne, MSE).

La Régression

- ❑ La régression sert à trouver la relation d'une variable par rapport à une ou plusieurs autres. $\hat{y}(x) = f(x_1, x_2, \dots, x_m)$
- ❑ Dans l'apprentissage automatique, le but de la régression est d'estimer une valeur (numérique) de sortie à partir des valeurs d'un ensemble de caractéristiques en entrée.
- ❑ Par exemple, estimer le prix d'une maison en se basant sur sa surface, nombre des étages, son emplacement, etc. Donc, le problème revient à estimer une fonction de calcul en se basant sur des données d'entraînement.

La Régression

❑ Étapes principales d'un algorithme de régression

1. Formuler une hypothèse (modèle)

- Exemple linéaire :

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

- \hat{y} = prédiction
- x_j = variables explicatives
- θ_j = paramètres/poids à apprendre

2. Définir une fonction de coût

- Mesure l'écart entre les valeurs prédites et réelles .
- Exemple : MSE (Erreur Quadratique Moyenne).

3. Optimiser les paramètres

- Utiliser un algorithme comme la **descente de gradient** pour ajuster les θ_j et **minimiser la fonction de coût**.

4. Évaluer le modèle

- Vérifier la qualité des prédictions avec des métriques (MSE, RMSE, R^2 , etc.).

La Régression

❑ Formuler une hypothèse : Modèles de Régression

❑ Régression linéaire :

But : établir un lien entre une variable dépendante Y et une variable indépendante X pour pouvoir ensuite faire des prévisions sur Y lorsque X est mesurée.

Exemple 1

L'analyse de la température de fonctionnement d'un procédé chimique sur le rendement du produit a donné les valeurs suivantes pour la température X_i et le rendement correspondant Y_i :


Température °C	Rendement %	Température °C	Rendement %
100	45	150	70
110	51	160	74
120	54	170	78
130	61	180	85
140	66	190	89

La Régression

☐ Formuler une hypothèse : Modèles de Régression

☐ Régression linéaire : Exemple 1 (suite)

Le graphe ci-dessous représente les points (X_i, Y_i) pour ces données et suggère une relation linéaire entre X et Y .




La Régression

□ Formuler une hypothèse : Modèles de Régression

□ Régression linéaire : Régression linéaire simple

- **Principe** : on cherche la **meilleure droite** qui passe au plus près des points.



Modèle linéaire

$$f(x) = ax + b$$

on laisse la machine trouver la valeur de a et b qui donne les meilleurs résultats.

Exemple : prédire le **prix d'un appartement** en fonction de sa **surface**.


La Régression

❑ Formuler une hypothèse : Modèles de Régression

❑ Régression linéaire : Régression linéaire multiple

- **Principe** : on ajoute plusieurs variables explicatives.

$$y = a_0 + a_1x_1 + a_2x_2 + \dots + a_px_p$$




Exemple : prédire le **prix d'un appartement** en fonction de la **surface**, **localisation**, **nombre de chambres**.

La Régression

❑ Formuler une hypothèse : Modèles de Régression

❑ Régression linéaire : Régression polynomiale (non linéaire)

- **Principe** : au lieu d'une droite, on ajuste une **courbe** (polynôme).




$$y = a_0 + a_1x + a_2x^2 + a_3x^3 + \dots + a_px^p$$

La Régression

❑ FONCTION COÛT

- ❑ La **fonction de perte (ou fonction de coût)** est une fonction mathématique qui mesure l'écart entre la **prédiction du modèle** et la **valeur réelle attendue**.

$$Loss_{function} = f(f(x), y)$$




- La **loss function** calcule l'erreur → plus l'écart est grand, plus la perte est élevée.
- Objectif de l'apprentissage : **minimiser la fonction de perte**.

La Régression

❑ FONCTION COÛT

❑ Les fonctions coût possibles en régression :


- Erreur Quadratique Moyenne (Mean Squared Error, MSE)
- MAE (Mean Absolute Error)
- RMSE (Root Mean Squared Error)
- Huber Loss – Combinaison de MSE et MAE (utile quand il y a des outliers)



La Régression

❑ Algorithme d'optimisation

- Quels sont les paramètres (les coefficients de la fonction de notre modèle) qui minimise la fonction coût (l'erreur entre la valeur estimée et la valeur réelle)?
- on utilise un algorithme d'optimisation
 - Descente de gradient : algorithme de minimisation qui considère la Fonction Coût comme une fonction **convexe**.




La Régression : Régression Linéaire simple

❑ Le Dataset

- ❑ On veut développer un modèle de Machine Learning à partir d'un Dataset à une seule variable x_1
- ❑ On aura donc un Dataset avec m exemples et $n=1$ « *feature* » variable.
- ❑ Ce Dataset représente le prix d'un appartement y en fonction de sa surface habitable x dans une ville donnée. Ce Dataset pourrait nous donner le nuage de point suivant :

Prix y en €	Surface x m^2
350,000	100
160,000	50
280,000	80
...	...
235,000	75

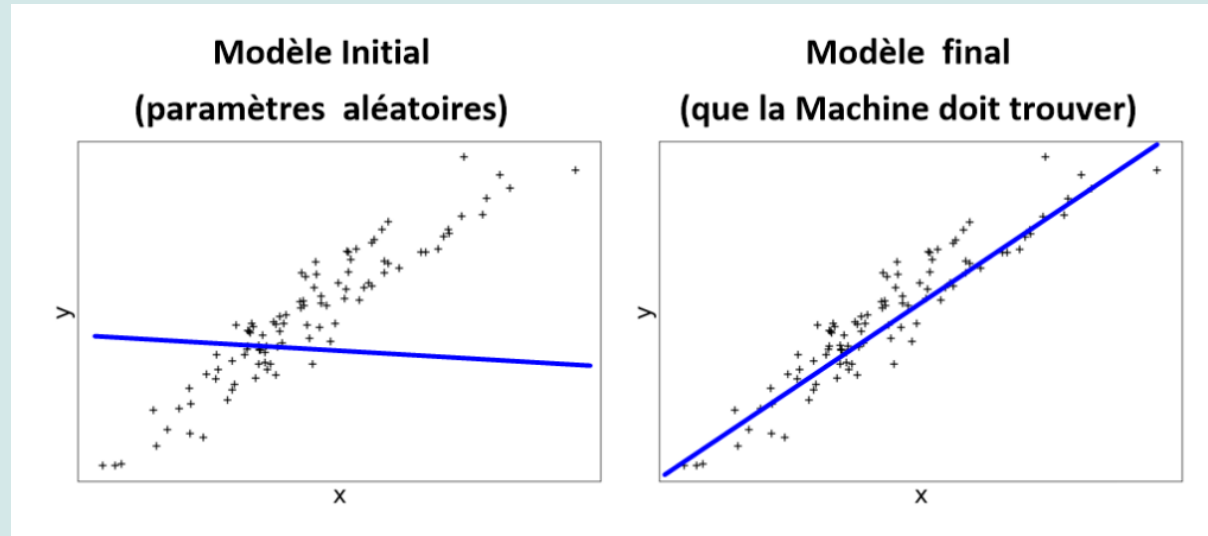


y	x
$y^{(1)}$	$x^{(1)}$
$y^{(2)}$	$x^{(2)}$
$y^{(3)}$	$x^{(3)}$
...	...
$y^{(m)}$	$x^{(m)}$

La Régression : Régression Linéaire simple

❑ Le Modèle

- ❑ D'après le nuage de point, on remarquait clairement qu'il suit une **tendance linéaire**, Notre modèle : $f(x) = ax + b$
- ❑ Pour le moment, nous ne connaissons pas la valeur des **paramètres** a et b
- ❑ Il est donc impossible de tracer une bonne droite sur le nuage de point, à moins de choisir des paramètres au hasard.
- ❑ Ce sera le rôle de la machine **d'apprendre** ces valeurs en minimisant la fonction coût.



La Régression : Régression Linéaire simple

❑ La Fonction Coût : L'Erreur Quadratique Moyenne

❑ La fonction coût nous permet d'évaluer la performance de notre modèle en mesurant les erreurs entre $f(x^{(i)})$ et $y^{(i)}$


➔ Comment mesurer ces erreurs ?

❑ Imaginez visiter un appartement à 200000 DT. Votre modèle de Machine Learning prédit que cet appartement vaut 300000 DT. Vous pourriez conclure que votre modèle fait donc une erreur de $300000 - 200000 = 100000$ DT.

➔ Ainsi, on pourrait se dire que pour mesurer nos erreurs, il faut faire calculer la différence $f(x) - y$

Cependant, si votre prédiction $f(x)$ est inférieure à y , alors cette erreur est négative, ce qui n'est pas pratique

❑ Pour mesurer les erreurs entre les prédictions $f(x)$ et les valeurs y du Dataset on calcule le carré de la différence $(f(x) - y)^2$: la **norme euclidienne**, qui représente la distance directe entre $f(x)$ et y



La Régression : Régression Linéaire simple

❑ La Fonction Coût : L'Erreur Quadratique Moyenne

❑ Pour la régression linéaire, la fonction Coût J va être la moyenne de toutes nos erreurs, c'est-à-dire :


$$J = \frac{[f(x^{(1)}) - y^{(1)}]^2 + \dots + [f(x^{(m)}) - y^{(m)}]^2}{m}$$

❑ Par convention on écrit cette fonction de la manière suivante, en rajoutant un coefficient $\frac{1}{2}$

→ pour simplifier un calcul de dérivée qui viendra par la suite

$$J(a, b) = \frac{1}{2m} \sum_{i=1}^m (f(x^{(i)}) - y^{(i)})^2$$

$$J(a, b) = \frac{1}{2m} \sum_{i=1}^m (ax^{(i)} + b - y^{(i)})^2$$



❑ Cette fonction porte un nom : en français on l'appelle **l'Erreur Quadratique Moyenne**, et en anglais elle s'appelle **Mean Squared Error**.

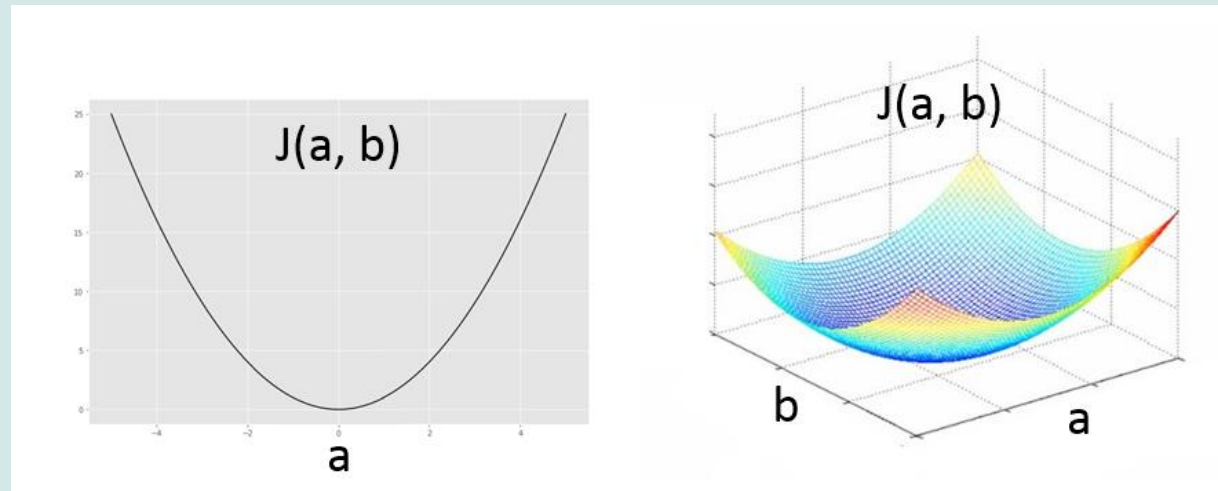
La Régression : Régression Linéaire simple

❑ Mean Squared Error

❑ Fonction dépend de deux paramètres : a et b

❑ **Convexe par rapport à a et b** : permet de trouver un **minimum global** → Cela garantit que la **descente de gradient** converge vers le **minimum global**

❑ Cette propriété est très importante pour s'assurer de converger vers le minimum avec l'algorithme de la **descente de gradient**.



La Régression : Régression Linéaire simple

□ R^2 : coefficient de détermination

- Il mesure la **proportion de la variance des données expliquée par le modèle**.
- Indique **dans quelle mesure le modèle suit la tendance des données réelles**.

$$R^2 = 1 - \frac{SS_{\text{résiduelle}}}{SS_{\text{totale}}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

y_i : valeur réelle

\hat{y}_i : valeur prédite par le modèle

\bar{y} : moyenne des valeurs réelles

$SS_{\text{résiduelle}}$: somme des carrés des erreurs

SS_{totale} : somme des carrés totaux

- Indique la **proportion de la variation totale des données expliquée par le modèle**.
 - $R^2 = 1 \rightarrow$ modèle parfait
 - $R^2 = 0 \rightarrow$ le modèle ne fait pas mieux que la moyenne
 - $0 < R^2 < 1 \rightarrow$ proportion de variance expliquée.

La Régression : Régression Linéaire simple

❑ L'algorithme d'apprentissage : Méthodes d'optimisation

- ❑ On dit que la machine apprend quand elle trouve quels sont les paramètres du modèle qui **minimisent** la fonction Coût.
- ❑ On cherche donc à développer un **algorithme de minimisation**.
- ❑ Il existe un paquet de méthodes de minimisation (méthode des moindres carrés, méthode de Newton, Gradient Descent, Simplex, etc.)
- ❑ Pour un modèle de régression linéaire, on utilise le plus souvent **la méthode des moindres carrés** (quand le problème est simple) et l'algorithme de **Gradient Descent** (pour les régressions plus compliquée).
- ❑ Le Gradient Descent, permet de converger progressivement vers le minimum de n'importe quelle fonction **convexe** (comme la Fonction Coût) en suivant la direction de la pente (le gradient) qui descend, d'où son nom de Gradient Descent.

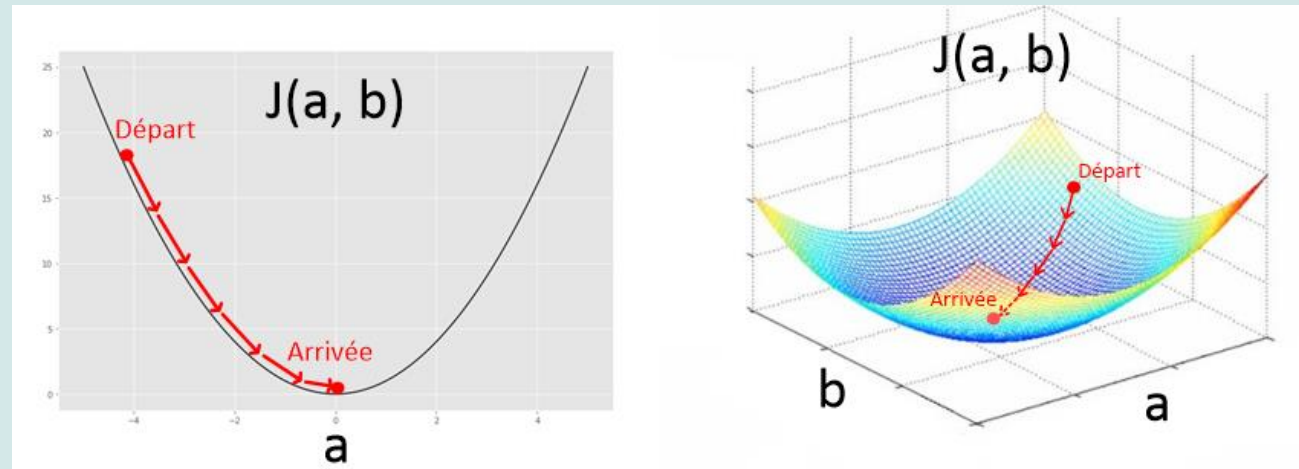
La Régression : Régression Linéaire simple

❑ Méthodes d'optimisation

❑ Pour un modèle de régression linéaire, on utilise le plus souvent :

- la **méthode des moindres carrés** → quand le problème est simple
- l'algorithme de **Gradient Descent** → pour les régressions plus compliquées

❑ Le Gradient Descent, permet de converger progressivement vers le minimum de n'importe quelle fonction **convexe** (comme la Fonction Coût) en suivant la direction de la pente (le gradient) qui descend, d'où son nom de Gradient Descent.



La Régression : Régression Linéaire simple

□ L'algorithme d'apprentissage: Méthode des moindres carrés (Ordinary Least Squares – OLS)

- la méthode **classique et exacte** utilisée quand le modèle de régression est **simple**.
- L'idée est de trouver la **droite la plus proche possible des points** en minimisant la **somme des carrés des erreurs**.

$$\text{Minimiser } \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

où

- y_i : valeur réelle
- $\hat{y}_i = ax_i + b$: valeur prédite

- Il existe une **formule directe** pour calculer les paramètres :

$$a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$b = \bar{y} - a\bar{x}$$

La Régression : Régression Linéaire simple

❑ L'algorithme d'apprentissage: Descente de gradient (Gradient Descent)

- Méthode **numérique et itérative** utilisée quand le modèle est **complexe** ou contient **beaucoup de variables**.
- L'idée est de **partir d'une estimation aléatoire** des paramètres (poids), puis de les **ajuster progressivement** pour **minimiser l'erreur (coût)**.

▪ Étapes de l'algorithme

Régression Linéaire: Résumé des équations

- **Dataset** : (x, y) avec m exemples

- **Modèle** : $f(x) = ax + b$


- **Fonction Coût** : $J(a, b) = \frac{1}{2m} \sum_{i=1}^m (ax^{(i)} + b - y^{(i)})^2$

- **Gradients** :

$$\frac{\partial J(a, b)}{\partial a} = \frac{1}{m} \sum_{i=1}^m x^{(i)} (ax^{(i)} + b - y^{(i)})$$

$$\frac{\partial J(a, b)}{\partial b} = \frac{1}{m} \sum_{i=1}^m (ax^{(i)} + b - y^{(i)})$$

- **Algorithme de Gradient Descent** :


$$\begin{cases} a := a - \alpha \frac{\partial J(a, b)}{\partial a} \\ b := b - \alpha \frac{\partial J(a, b)}{\partial b} \end{cases}$$

La Régression : Régression Linéaire simple

❑ Moindres carrés

❑ Avantages :

- Donne la **solution exacte** pour a et b qui minimisent la MSE.
- Très **rapide à calculer** avec une petite formule analytique.
- Convient parfaitement aux petits datasets simples.

❑ Inconvénients :

- Si le problème devient très complexe ou multivarié, la formule peut devenir lourde.

❑ Descente de gradient

❑ Avantages :

- Peut résoudre des problèmes très complexes ou avec beaucoup de variables.
- Nécessaire pour les grands datasets ou des modèles non linéaires.

❑ Inconvénients :

- Solution approximative, nécessite **plusieurs itérations** pour converger.
- Le choix du **taux d'apprentissage** α est crucial.
- Pour un seul pas, les résultats sont **très approximatifs**.

La Régression : Régression Linéaire simple

❑ Exercice d'application

On étudie la relation entre la vitesse d'une voiture (en km/h) et sa consommation de carburant (en L/100 km). On dispose du dataset suivant :

Essai	Vitesse (km/h)	Consommation (L/100 km)
1	40	7.5
2	60	6.8
3	80	6.5
4	100	6.7
5	120	7.2

Questions

1. Définir la fonction de coût MSE pour une droite $y = a x + b$.
2. Méthode analytique (moindres carrés) : calculer a et b qui minimisent la MSE.
3. Descente de gradient : effectuer manuellement un pas avec $\alpha = 0.01$, $a_0 = 0$, $b_0 = 0$.
4. Estimer la consommation pour une voiture roulant à 90 km/h.

La Régression : Régression Linéaire simple

❑ Exercice d'application

1. la fonction de coût MSE pour : $y=f(x)$

$$f(x) = ax + b$$

$$J(a, b) = \frac{1}{2m} \sum_{i=1}^m (f(x^{(i)}) - y^{(i)})^2$$

La Régression : Régression Linéaire simple

❑ Exercice d'application

Méthode analytique (moindres carrés)

Formules :

$$a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$
$$b = \bar{y} - a\bar{x}$$

Données :

$$\bar{x} = 80, \quad \bar{y} = 6.94$$

Calcul :

$$a = \frac{-36}{4000} = -0.009$$

$$b = 6.94 - (-0.009)(80) = 6.94 + 0.72 = 7.66$$

Équation de la droite :

$$y = -0.009x + 7.66$$

La Régression : Régression Linéaire simple

❑ Exercice d'application : 2. descente de gradient iteration 1:

Formules

$$J(a, b) = \frac{1}{2m} \sum_{i=1}^m (ax^{(i)} + b - y^{(i)})^2$$

$$\frac{\partial J}{\partial a} = \frac{1}{m} \sum_{i=1}^m x^{(i)} (ax^{(i)} + b - y^{(i)}) \quad \frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^m (ax^{(i)} + b - y^{(i)})$$

Calcul des résidus pour $a_0 = 0, b_0 = 0$

Pour chaque i , $a_0 x_i + b_0 - y_i = 0 \cdot x_i + 0 - y_i = -y_i$.

Donc :

$$\sum_{i=1}^5 x_i (a_0 x_i + b_0 - y_i) = \sum_{i=1}^5 x_i (-y_i) = - \sum_{i=1}^5 x_i y_i = -2189.0.$$

$$\sum_{i=1}^5 (a_0 x_i + b_0 - y_i) = \sum_{i=1}^5 (-y_i) = - \sum_{i=1}^5 y_i = -34.7.$$

La Régression : Régression Linéaire simple

❑ Exercice d'application : 2. descente de gradient iteration 1

Gradients (valeurs numériques)

$$\left. \frac{\partial J}{\partial a} \right|_{(0,0)} = \frac{1}{m} \sum_i x_i (a_0 x_i + b_0 - y_i) = \frac{1}{5} \cdot (-2189.0) = -\frac{2189.0}{5}$$

$$\Rightarrow \frac{\partial J}{\partial a} = -437.8$$

$$\left. \frac{\partial J}{\partial b} \right|_{(0,0)} = \frac{1}{5} \cdot (-34.7) = -\frac{34.7}{5}$$

$$\Rightarrow \frac{\partial J}{\partial b} = -6.94$$

La Régression : Régression Linéaire simple

❑ Exercice d'application : 2.descente de gradient iteration1

• Mise à jour des paramètres

Règle : $a := a - \alpha \frac{\partial J}{\partial a}$, $b := b - \alpha \frac{\partial J}{\partial b}$ avec $\alpha = 0.01$.

Calculs :

- Pour a :

$$a_1 = a_0 - 0.01 \cdot (-437.8) = 0 - 0.01 \cdot (-437.8).$$

$$a_1 = 0 + 4.378 = \boxed{4.378}.$$

- Pour b :

$$b_1 = b_0 - 0.01 \cdot (-6.94) = 0 - 0.01 \cdot (-6.94).$$

$$b_1 = 0 + 0.0694 = \boxed{0.0694}.$$

$$\boxed{y = 4.378x + 0.0694.}$$

La Régression : Régression Linéaire simple

❑ Exercice d'application: 3 prediction

Prédiction — Moindres carrés

$$y(90) = -0.009 \times 90 + 7.66$$

$$y(90) = 6.85 \text{ L/100 km}$$

Prédiction — Descente de gradient (1 itération)

$$y(90) = 4.378 \times 90 + 0.0694$$

$$y(90) = 394.09 \text{ L/100 km}$$

Valeur très approximative, car un seul pas n'a pas encore convergé.